



PRUEBA DE DESEMPEÑO

Analítica datos

1. Contexto del negocio

Toda organización que quiere tomar decisiones basadas en datos enfrenta el mismo reto: la información nace dispersa, cruda e inconsistente en archivos planos, sistemas transaccionales u hojas de cálculo, y debe transformarse en algo confiable, estructurado y fácil de consultar antes de que sirva para decidir.

En esta prueba tú cumples el rol de analista/ingeniero de datos encargado de construir ese primer pipeline: partirás de un dataset real de tu elección, con una problemática de negocio que tú mismo definas, y demostrarás que eres capaz de llevar esa información desde su estado crudo hasta un tablero interactivo que responda preguntas concretas para la toma de decisiones.

No se te entrega un dataset ni una empresa ficticia: la elección del dominio, del dataset y de la problemática de negocio es parte de lo que se evalúa. Se espera que definas un caso realista y lo sostengas de principio a fin en tu pipeline, tu modelo de datos y tu tablero.

2. Objetivo de la prueba

El objetivo es que construyas una solución funcional de extremo a extremo: desde la selección de un dataset con una problemática de negocio real, pasando por un proceso ETL con pandas, hasta un tablero interactivo en Power BI conectado a una base de datos PostgreSQL que responda preguntas concretas para la toma de decisiones.

Se espera que puedas:

- Identificar y justificar una problemática de negocio a partir de un dataset real, formulando preguntas relevantes para la toma de decisiones.
- Diseñar el flujo completo de tu pipeline de datos (extracción, transformación, carga y consumo) antes de programar.
- Aplicar un proceso ETL con pandas: limpieza de datos, manejo de nulos y duplicados, corrección de tipos, y creación de columnas derivadas con sentido de negocio.
- Validar la calidad de los datos después de transformarlos (nulos, duplicados, rangos válidos) y documentar los hallazgos.
- Modelar y cargar los datos en PostgreSQL usando SQLAlchemy, aplicando buenas prácticas de diseño (esquema, tipos de datos, llaves).
- Conectar Power BI a la base de datos PostgreSQL mediante el conector nativo, sin depender de archivos planos como fuente final.
- Construir un tablero interactivo (KPIs, tendencia, ranking, distribución, filtros) que responda como mínimo cinco preguntas de negocio.
- Interpretar los resultados del tablero y redactar conclusiones e insights accionables para la toma de decisiones.
- Documentar y versionar tu trabajo de forma clara para que otra persona pueda reproducirlo.



3. Entorno técnico — Cómo debe quedar configurado

El pipeline debe poder ejecutarse de forma reproducible en cualquier máquina. El repositorio debe incluir todo lo necesario para que un evaluador pueda correr tu proceso de principio a fin sin configuración manual adicional:

- Script(s) de Python con las librerías pandas, sqlalchemy y psycopg2 (o psycopg2-binary).
- Una base de datos PostgreSQL (local o en contenedor Docker) que funcione como repositorio analítico destino del pipeline.
- Script(s) DDL de creación de tablas, o creación automática de tablas desde el script de carga.
- Archivo de variables de entorno de ejemplo (.env.example) con la cadena de conexión y credenciales necesarias. El archivo .env real debe excluirse mediante .gitignore — ningún usuario, contraseña o cadena de conexión debe aparecer directamente en el código fuente.
- Power BI Desktop, conectado a PostgreSQL mediante el conector nativo (no mediante exportación a CSV).

4. Fuentes de datos

Selecciona un dataset relacionado con un dominio de negocio de tu preferencia (ventas, e-commerce, RRHH, salud, finanzas, marketing, logística, etc.), descargado de Kaggle o de otra fuente pública confiable. El dataset debe cumplir:

- Mínimo 5 columnas y 1.000 filas.
- Al menos una columna de tipo fecha/tiempo.
- Al menos una columna categórica y una numérica, para permitir agregaciones.
- Debe permitir formular una problemática de negocio concreta y preguntas relevantes para la toma de decisiones.

Al explorar tu dataset es probable que encuentres situaciones que requieren una decisión de tu parte: valores nulos en campos clave, registros duplicados, categorías escritas de forma inconsistente (mayúsculas/minúsculas), o registros con valores fuera de rango (precios o cantidades negativas). No existe una única forma correcta de tratar cada caso: deberás tomar una decisión para cada uno y justificarla en tu documentación.



5. Reglas de negocio y casos de ambigüedad

Reglas mínimas que debe cumplir tu pipeline:

- Ningún registro con valores nulos en las columnas clave (fecha, métrica principal, identificador) debe llegar sin tratar al repositorio analítico: se corrige, se descarta o se marca explícitamente — la decisión debe ser tuya y estar documentada.
- Los duplicados deben eliminarse antes de la carga; el criterio de qué constituye un duplicado debe quedar explícito en el código.
- Todas las fechas deben quedar estandarizadas a un único formato antes de cargarlas al repositorio analítico.
- Los valores de texto usados para agrupar o filtrar (categoría, región, producto) deben normalizarse (mayúsculas/minúsculas, espacios) antes de la carga.
- El pipeline debe calcular al menos dos métricas derivadas con sentido de negocio (por ejemplo, ingreso total, variación porcentual, categoría de precio).

Casos ambiguos que deberás resolver:

- Registros con valores atípicos o inconsistentes (precios en cero, cantidades negativas): decide si se excluyen, se corrigen o se separan en una categoría distinta, y documenta el impacto de tu decisión.
- Registros sin identificador de cliente o de producto: decide si los incluyes en el análisis, con qué valor los representas, o si los excluyes.
- Variaciones de escritura para un mismo valor categórico (ej. 'Bogotá', 'bogota', 'BOGOTÁ'): decide cuál es el valor canónico y cómo lo unificas.

6. Alcance técnico — Qué se espera construir

Exploración y limpieza

Antes de cargar cualquier dato al repositorio analítico, deberás explorar tu fuente y documentar lo que encuentres: estructura de columnas, tipos de dato, valores nulos, rangos y duplicados. Para cada problema de calidad debes decidir si el registro se corrige, se descarta o se trata de otra forma, dejando esa lógica en el código de forma explícita y legible.

Modelado del repositorio analítico

Una vez limpios los datos, deberás decidir cómo organizar la información en PostgreSQL: cuántas tablas, cómo se llaman, qué columnas tienen y cómo se relacionan (se sugiere un modelo tipo estrella con tablas de hechos y dimensiones, aunque no es obligatorio). El modelo debe ser coherente con las preguntas de negocio de la sección 7. Deberás justificar tu diseño en la documentación.



Tablero de Power BI

Power BI debe conectarse directamente a PostgreSQL mediante el conector nativo. El tablero debe incluir al menos: 1 tarjeta (KPI) resumen, 1 gráfico de tendencia temporal, 1 gráfico de ranking/top-N, 1 gráfico de distribución, y al menos 1 filtro o segmentador interactivo.

7. Preguntas de negocio

Las preguntas de negocio no se te entregan: debes formularlas tú mismo a partir de tu dataset y de la problemática que definiste en la sección 4. Esto es parte de lo que se evalúa — un analista de datos debe saber traducir un problema de negocio en preguntas que los datos puedan responder.

Tus preguntas deben cumplir:

- Mínimo 5 preguntas de negocio distintas.
- Cada pregunta debe aportar valor real para la toma de decisiones — evita preguntas triviales o puramente descriptivas (ej. "¿cuántas filas tiene el dataset?" no es una pregunta de negocio).
- En conjunto, tus preguntas deben cubrir distintos tipos de análisis: al menos una debe abordar una tendencia temporal, al menos una debe comparar categorías o segmentos (ranking/top-N), al menos una debe analizar distribución o concentración entre grupos, y al menos una debe comparar dos periodos o explorar la relación entre dos variables.
- Cada pregunta debe ser respondible directamente con los datos que cargaste — si no puedes responderla con tu dataset, replantéala.
- Cada pregunta debe quedar representada en el tablero por un visual claro (KPI, gráfico de tendencia, ranking, distribución o dispersión) y debe poder validarse con una consulta SQL sobre tu repositorio analítico.

Ejemplos del tipo de pregunta esperado (no son las tuyas, son una referencia de nivel de profundidad): "¿cómo ha evolucionado la métrica principal en el tiempo?", "¿qué categorías o productos concentran el mejor y el peor desempeño?", "¿cómo se distribuye la métrica entre regiones, canales o segmentos?", "¿cuál fue la variación entre dos periodos comparables?", "¿existe relación entre dos variables clave del negocio?".

Además, deberás responder en tu documento de conclusiones: con base en tus propias preguntas y los datos, ¿qué recomendación concreta y específica le harías al negocio? La recomendación debe estar respaldada por números del análisis, no ser genérica.



8. Entregables

Repositorio Git

El repositorio debe estar organizado reflejando buenas prácticas: separación de responsabilidades entre archivos, nombres descriptivos, sin archivos temporales ni binarios innecesarios. Debe incluir como mínimo: el/los script(s) de ETL, el archivo `.env.example`, los scripts DDL o de creación de tablas, y el dataset fuente (o instrucciones claras de dónde descargarlo).

Ficha del dataset, problemática de negocio y preguntas

Descripción breve (5-10 líneas): origen del dataset, número de filas/columnas, la problemática de negocio que abordas, por qué elegiste ese dataset, y el listado de tus mínimo 5 preguntas de negocio con una frase que justifique el valor de cada una para la toma de decisiones.

Diagrama del flujo de datos

Una imagen o PDF que muestre el flujo completo: fuente, extracción, transformación, carga y consumo, incluyendo el nombre de las tablas destino en PostgreSQL.

Documento de decisiones técnicas

Un documento (puede ser una sección del README o un archivo separado) en el que expliques: cómo diseñaste el modelo del repositorio analítico y por qué, cómo resolviste cada uno de los casos ambiguos de la sección 5, y qué conclusiones e insights obtuviste del análisis.

Archivo .pbix del tablero

El tablero de Power BI con las 5 preguntas de negocio respondidas, junto con capturas de pantalla de cada visual.

Sobre el tiempo disponible

Las 8 horas son suficientes para construir una solución funcional si priorizas bien. Empieza por explorar tu dataset y definir el modelo de datos antes de escribir código de transformación. Si no alcanzas a implementar algo, documenta en el documento de decisiones qué quedaba pendiente y cómo lo habrías resuelto: esa documentación tiene tanto valor como el código.